Алгоритмы и структуры данных

Алгоритмы на строках. Часть II
Месть Кнута-Морриса-Пратта

Кухтичев Антон

education

20 апреля 2024 года

Содержание занятия

- Технический долг
- Рабин-Карп
- Кнут-Моррис-Пратт (КМП)
- Алгоритм Ахо-Корасика

Напоминание отметиться на портале

и оставить отзыв
после лекции

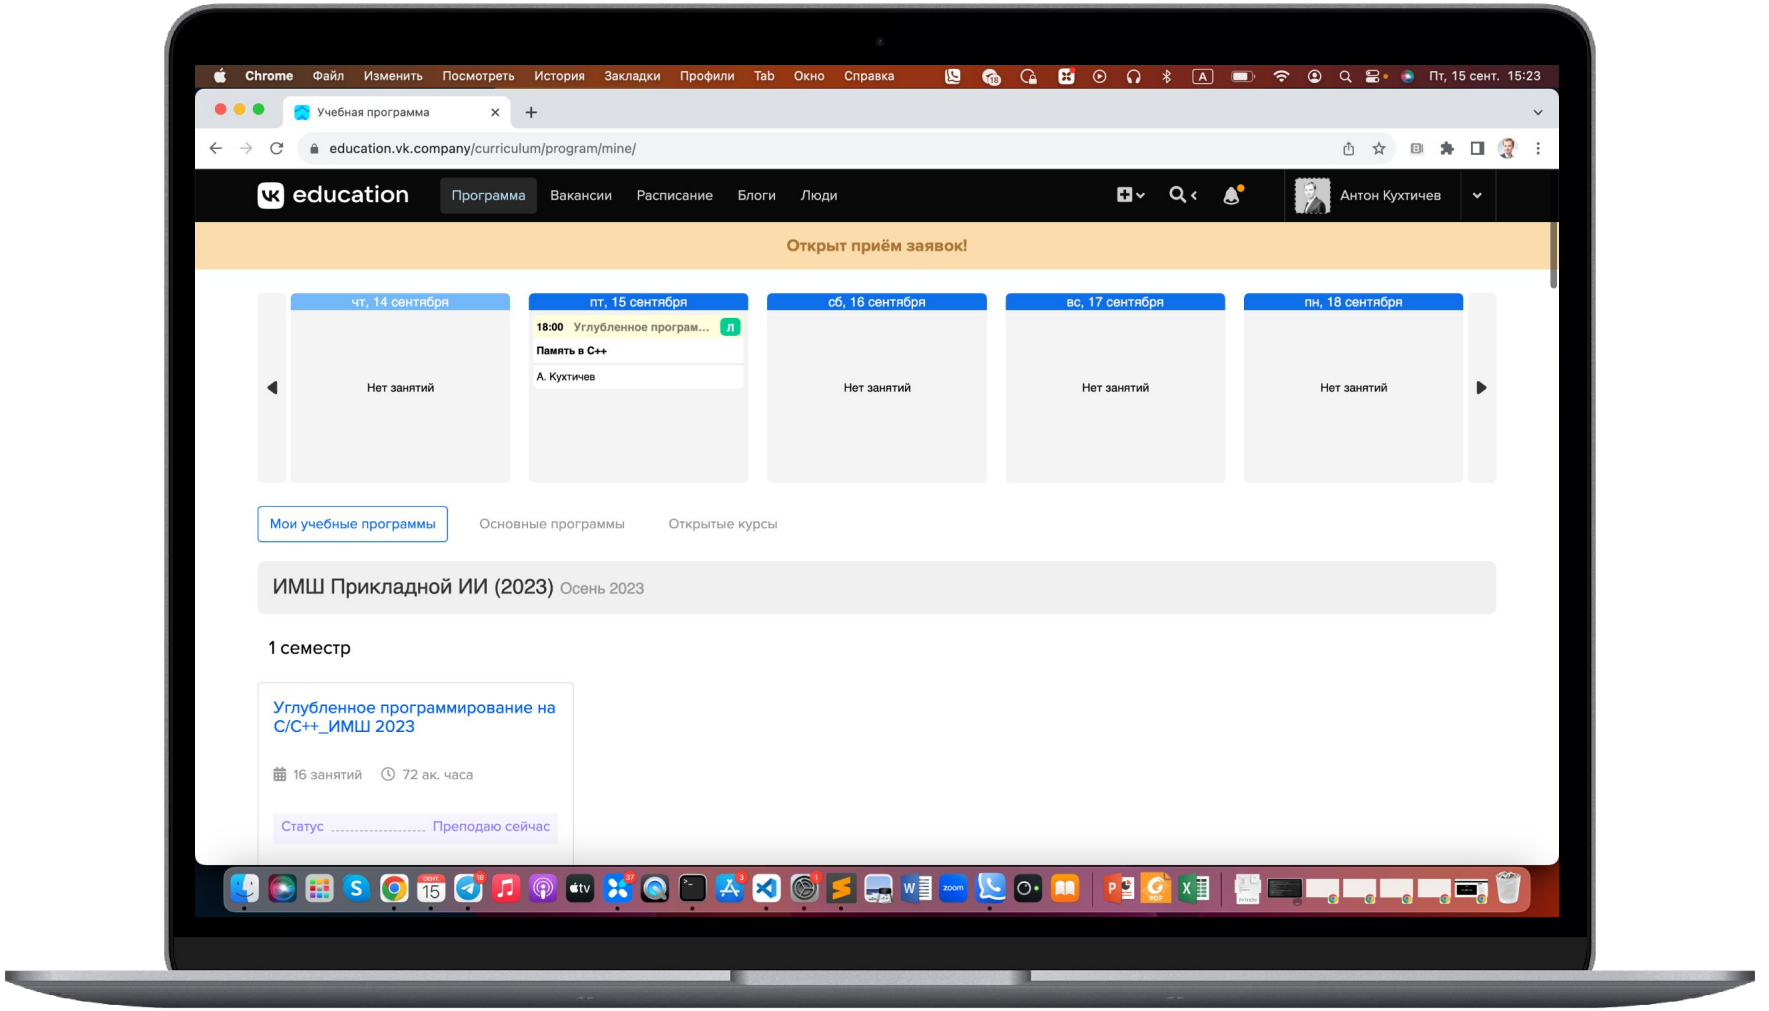

Литература

Строки, деревья и последовательности в алгоритмах - Гасфилд Д.М.

Технический долг

Упражнение #1

Реализовать алгоритм поиска подстроки, основанный на Z-блоках.

```
def z_algorithm(text: str, patter: str) -> bool:
    pass
```

https://interview.cups.online/live-coding/?room=d472e1a3-ff9f-4f4b-b96d-2f234478d8ef

Алгоритм Рабина-Карпа

Идея

- Дан текст T длины n и строка P длины m;
- Улучшение наивного алгоритма
- Сравниваем не символы, а хешы!

```
    012345678901
T = aabcaabxaaz   P0 = hash(aab), P1 = hash(abc), P2 = hash(bca)
P = aab           Ph = hash(aab)
```

Наивный алгоритм

```
rabin_karp(T, P):
   n = length(T)
   m = length(P)
   hp = hash(P[1..n])
   for i in 1..n-m+1 do
      ht = hash(T[i..i+m])
      if ht == hp then
        if T[i..i+m] = P then
            return i
        fi
      fi
   done
```

Упражнение #2

Реализовать простейший вариант поиска подстроки в строке при помощи алгоритма Рабина-Карпа

```
def rapin_karp(text: str, pattern: str) -> bool:
    pass
```

https://interview.cups.online/live-coding/?room=ee2ffa07-3c74-417e-9540-257c1782c1d3

Кнут-Морисс-Пратт

Идея

Для каждой позиции i образца P определим $sp_i(P)$ как длину наибольшего собственного суффикса P[1..i], который совпадает с префиксом P.

```
                  12345678901
P                 = abcaeabcabd
sp2 = sp3 = 0     abcaeabcabd
sp4 = 1           abcaeabcabd
sp8 = 3           abcaeabcabd
sp10 = 2          abcaeabcabd
```

Препроцессинг

- Нужно за линейное время определить все sp_i
- Позиция $j > 1$ отображается в i, если $i = j + Z_j(P) - 1$. То есть i - это правый конец Z-блока, начинающего в j.

```
for i := 1 to n do
  spi := 0
for j := n downto 2 do begin
  i := j + Zj(P) - 1
  spi := Zj
end
```

Алгоритм КМП

```
begin
  Обработать P, найдя F'(k) = sp'k-1 + 1 для k от 1 до n + 1.
  c := 1
  p := 1
  while c + (n - p) < m do begin
    while P(p) = T(c) и p ⩽ n do begin
      p := p + 1
      c := c + 1
    end
    if p == n + 1 then
      зафиксировать вхождение P в T, начиная с позиции c - n.
    if p == 1 then c := c + 1
    p := F'(P)
    end
  end
```

Упражнение #3

Реализовать поиск подстроки в строке при помощи алгоритма Кнута-Морриса-Пратта

```
def KnuthMorrisPratt(text: str, pattern: str) -> bool:
    pass
```

https://interview.cups.online/live-coding/?room=ced41f5b-db37-4765-8546-d8e588d1d9ab

Ахо-Корасик

Идея

- Задано множество образцов $P = \{P_1, P_2, \dots P_n\}$, требуется обнаружить вхождения в тексте T всех образцов.
- Если взять алгоритм поиска за линейное время, то сложность будет $O(n+zm)$
- Альфред Ахо и Маргарет Корасик предложили алгоритм поиска за $O(n+m+k)$, k – число вхождений в T образцов из P.

Дерево ключей

Деревом ключей (keyword tree) для множества P называется ориентированное дерево с корнем K, удовлетворяющее трем условиям:

1. каждая дуга помечена ровно одним символом;
2. любые две дуги, выходящие из одной и той же вершины, имеют разные пометки;
3. каждый образец P_i, в P отображается в некоторую вершину v из K, такую что символы на пути из корня K в v в точности составляют P, и каждый лист из K соответствует какому-либо образцу из P.

Дерево ключей

Дерево ключей для множества образцов {potato, poetry, pottery, science, school}

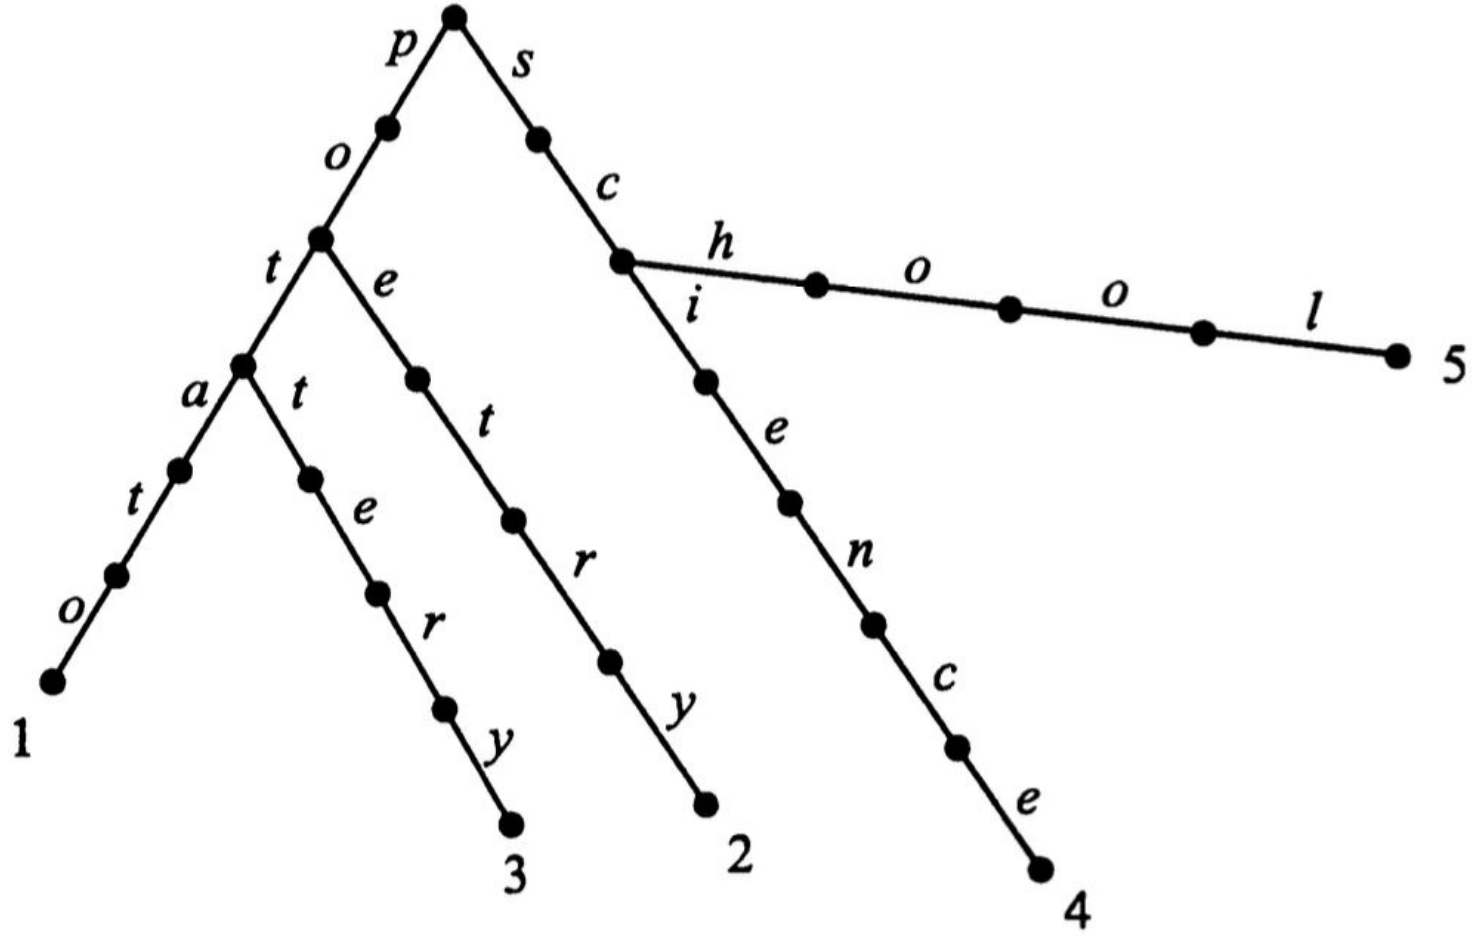

Функция неудач

Каждая вершина v в K помечена строкой, полученной конкатенацией символов на пути от корня K до вершины и в порядке их появления. Для этой пометки используется обозначение L(v). Так что конкатенация символов пути от корня до и произносит строку L(v).

Для любой вершины v дерева K определим lp(v) как длину наибольшего собственного суффикса строки L(v), которая является префиксом некоторого образца из P.

Функции неудач

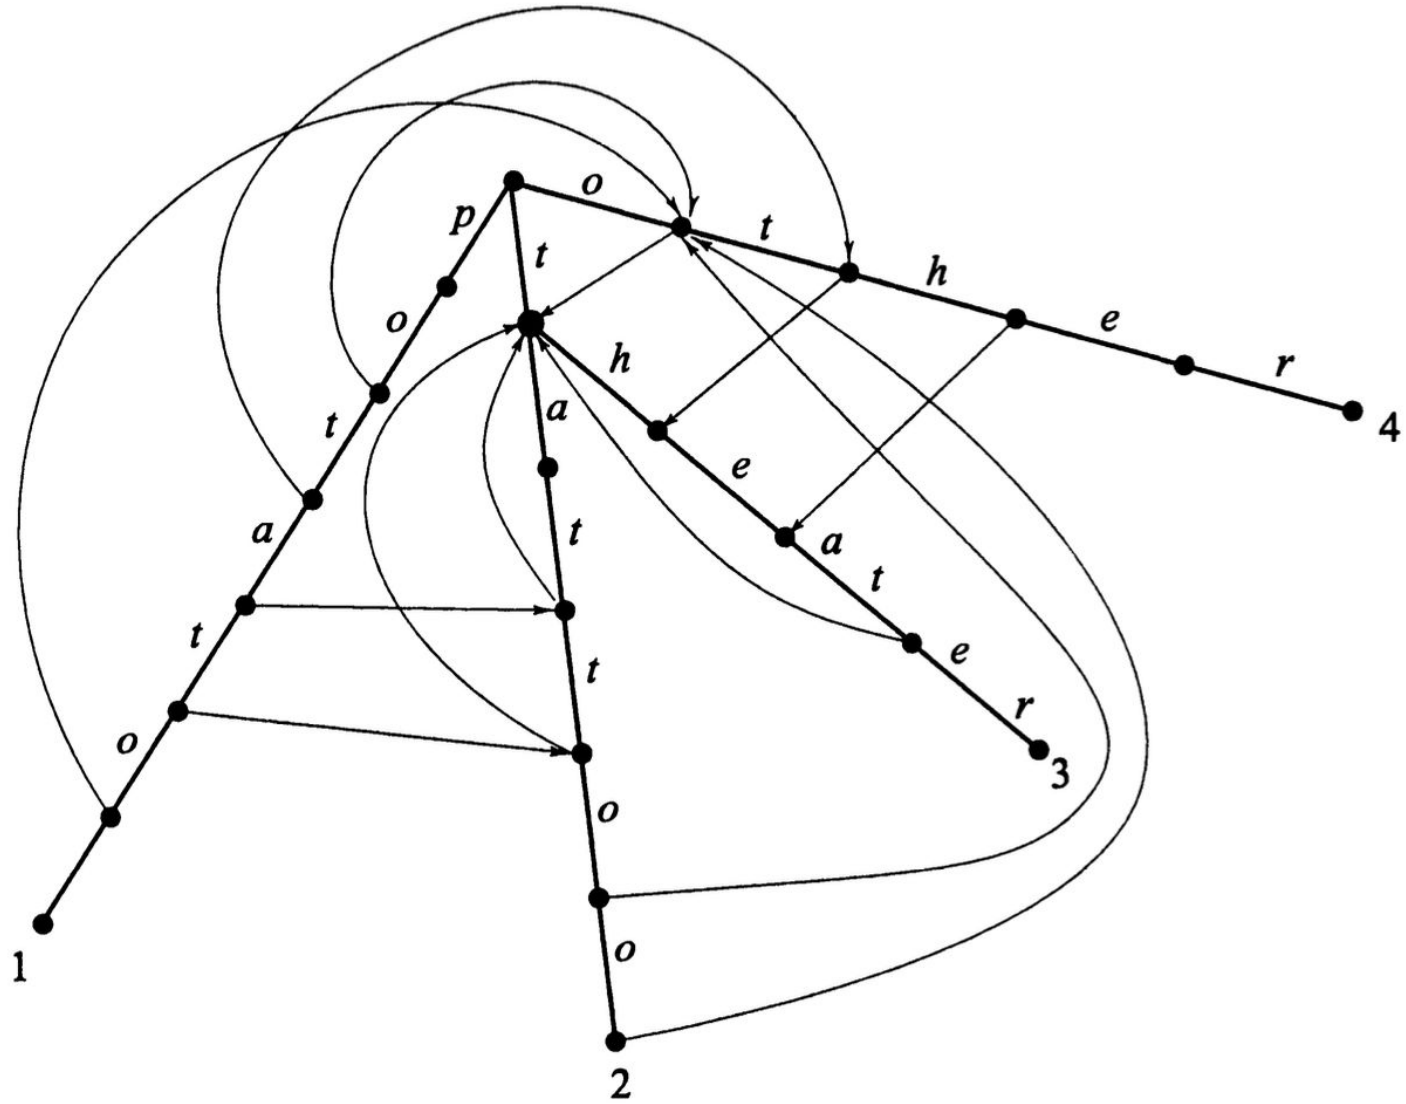

Алгоритм Ахо-Корасика

```
l := 1;
c := 1;
w := корень K
repeat
    while есть дуга (w, w'), помеченная символом T(c) begin
     if w' занумерована образцом i или существует путь из связей
неудач из w' в вершину с номером i; then
        сообщить, что P_i встретилось в T, начиная с позиции l;
    w := w'
    c := c + 1;
end;
w := n_w
l := c - lp(w)
until c > n;
```

Домашнее задание

Домашнее задание

Необходимо реализовать алгоритм Бойера-Мура поиска образцов для указанного алфавита.

Вариант алфавита: Слова не более 16 знаков латинского алфавита (регистронезависимые).

Напоминание оставить отзыв

Это правда важно

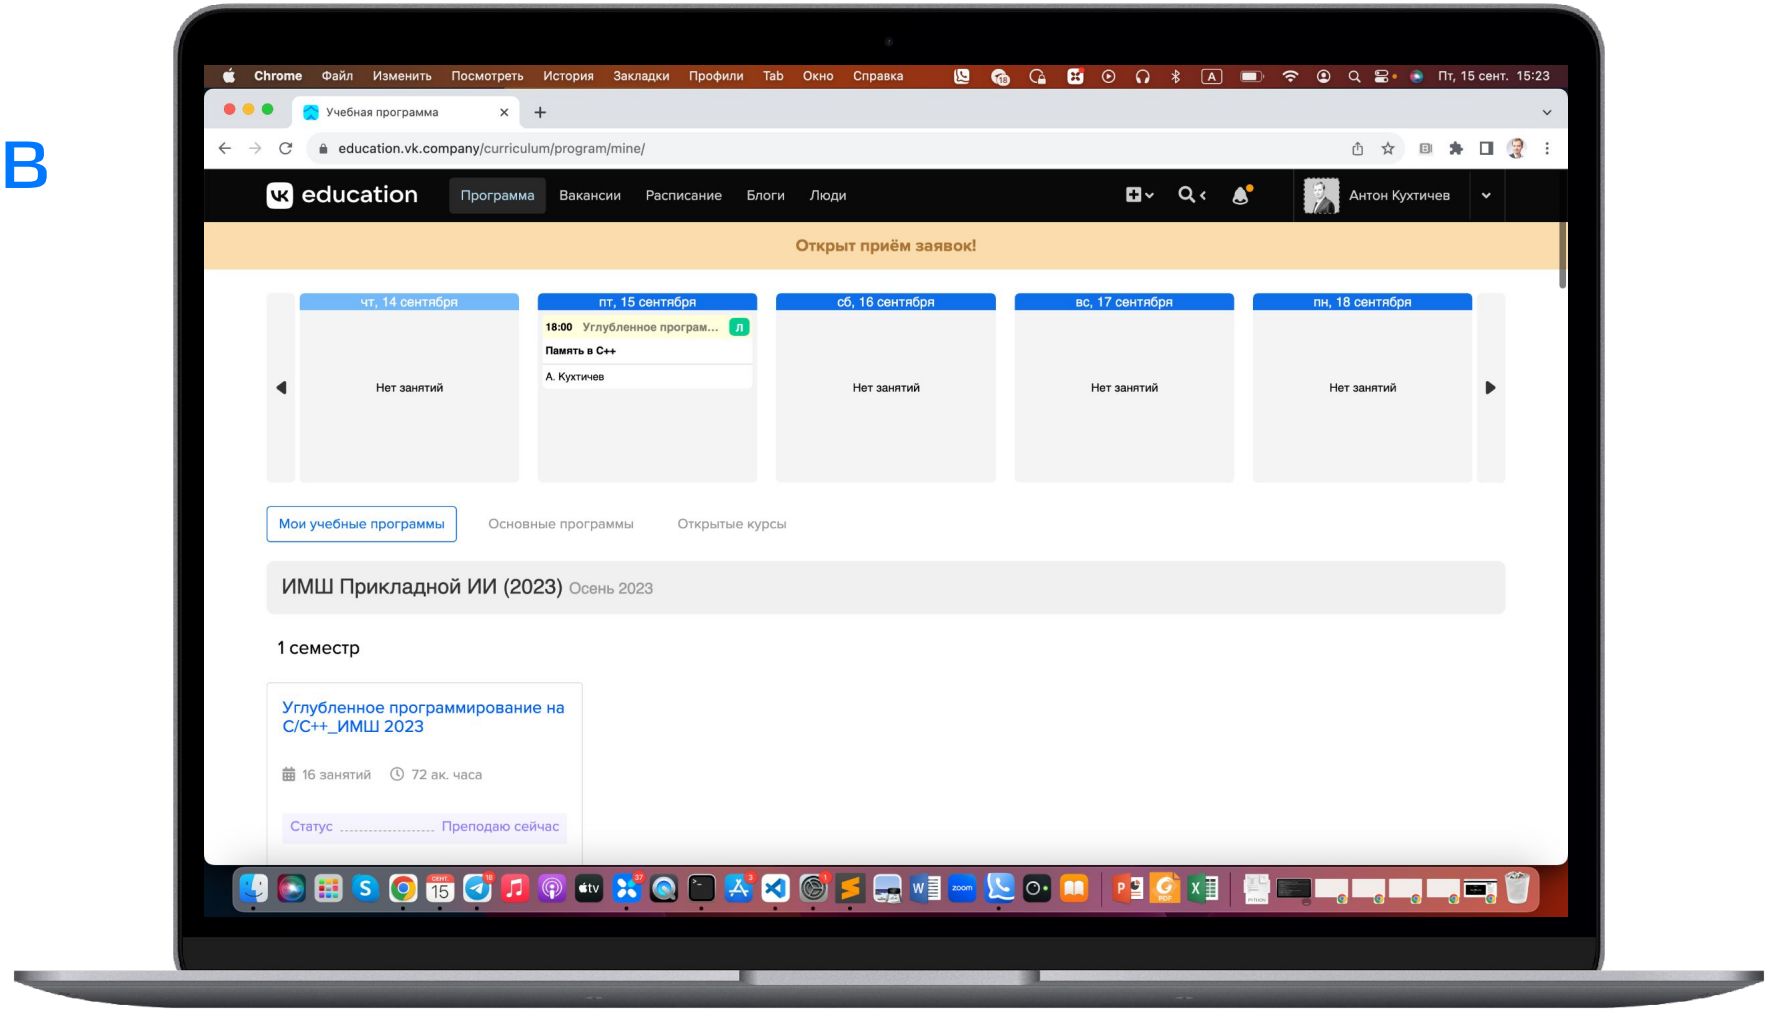

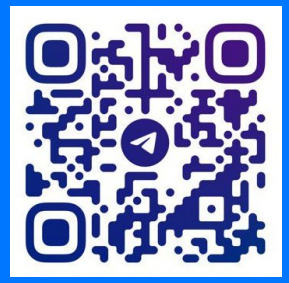

Спасибо
за внимание!